

Exercise 3 IML

Eyal Perets 209541903

התרגיל

$$\arg \min_{(w,b)} \|w\|^2 \quad \text{s.t.} \quad \forall_i: y_i (\langle w, x_i \rangle + b) \geq 1 \quad : \text{Hard SVM } 1$$

יש p נקודות, x_1, \dots, x_p ווקטורים ב- \mathbb{R}^d . Q, A — מטרices מסדר $p \times p$ ו- $p \times 1$ בהתאמה.
 $\arg \min \frac{1}{2} r^T Q r + a^T r \quad \text{s.t.} \quad Ar \leq d$

$$\arg \min \frac{1}{2} r^T Q r + a^T r \quad \text{s.t.} \quad Ar \leq d$$

בהנחה ש- $Ar \leq d$ נקבע r ונחשב w ו- b מתוך:

$$y_i (\langle w, x_i \rangle + b) \geq 1 \Leftrightarrow -y_i (\langle w, x_i \rangle + b) \leq -1 \Leftrightarrow$$

$$\Leftrightarrow -y_i (x_i^T w + b) \leq -1 \Leftrightarrow -y_i x_i^T w - y_i b \leq -1$$

$$r = \begin{bmatrix} w \\ b \end{bmatrix}$$

$$A = \begin{bmatrix} -y_1 x_1^T & \dots & -y_1 x_p^T & -y_1 \\ \vdots & & \vdots & \vdots \\ -y_p x_1^T & \dots & -y_p x_p^T & -y_p \end{bmatrix}$$

$$-y_i x_i^T w - y_i b = A r \leq -1$$

$$\|w\|^2 = w^T I w \quad \arg \min_{(w,b)} \|w\|^2$$

$$Q = \begin{bmatrix} I & 0 \\ 0 & 0 \end{bmatrix}$$

$$\arg \min w^T I w = \arg \min \begin{bmatrix} w \\ b \end{bmatrix}^T Q \begin{bmatrix} w \\ b \end{bmatrix} + 0^T \begin{bmatrix} w \\ b \end{bmatrix} = \arg \min r^T Q r + a^T r$$

$$= \arg \min \frac{1}{2} r^T Q r + a^T r$$

estimators: likelihood function → used for parameter estimation

likelihood function: $L(\theta | X, y)$

$$L(\theta | X, y) = f_{X, y | \theta}(\{X_i, y_i\}_{i=1}^n) = \prod_{i=1}^n f_{X, y | \theta}(X_i, y_i)$$

likelihood function →
$$= \prod_{i=1}^n N(X_i | \mu_{y_i}, \sigma_{y_i}^2) \cdot \text{Mult}(y_i, \pi)$$

we use loge to simplify the calculations, because the likelihood function is a product of many terms, and taking the log turns the product into a sum, which is easier to differentiate.

log-likelihood → $l(\theta | X, y)$

$$l(\theta | X, y) = \log \left(\prod_{i=1}^n N(X_i | \mu_{y_i}, \sigma_{y_i}^2) \cdot \text{Mult}(y_i, \pi) \right)$$

$$= \sum_{i=1}^n \log(N(X_i | \mu_{y_i}, \sigma_{y_i}^2)) + \log(\text{Mult}(y_i, \pi))$$

$$= \sum_{i=1}^n \log \left(\frac{1}{\sqrt{2\pi|\sigma^2|}} \cdot \exp \left(-\frac{1}{2} (X_i - \mu_{y_i})^T (\sigma^2)^{-1} (X_i - \mu_{y_i}) \right) \cdot \log(\pi_{y_i}) \right)$$

$$= \sum_{i=1}^n \log(\pi_{y_i}) - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log(|\sigma^2|) - \frac{1}{2} (X_i - \mu_{y_i})^T (\sigma^2)^{-1} (X_i - \mu_{y_i})$$

$$= \sum_k \left[n_k \log(\pi_k) - \frac{1}{2} \sum_{i: y_i=k} (X_i - \mu_k)^T (\sigma^2)^{-1} (X_i - \mu_k) \right] - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log|\sigma^2|$$

where $n_k = \sum_{i: y_i=k} 1$ is the number of observations in class k .

the likelihood function is a function of the parameters θ and the data (X, y) .

$$\sum_n \mu_n = 1 \quad \forall \epsilon \in [0, 1]^k \quad \text{e} \quad \text{ad} \quad \rho(\epsilon)$$

משפט
הנורמליזציה של פונקציית ההסתברות

כאשר $\sum_{k=1}^n p_k = 1$

לכן

הסתברות

$$\mathcal{L} = \ell(\theta | x, y) - \lambda g(\pi)$$

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{\partial}{\partial \pi_k} \cdot \mathcal{L}(\theta | x, y) - \lambda \frac{\partial}{\partial \pi_k} g(\pi) = \frac{n_k}{\pi_k} - \lambda = 0$$

$$n_k = \frac{n_q}{\lambda}$$

$$= \int_{\mathbb{R}^n} \int_{\mathbb{R}^n} \frac{1}{|x-y|} dx dy = \infty$$

$$\sum_{i=1}^m \frac{n_i}{\lambda} = 1 \Leftrightarrow m = \lambda$$

$$R_L^{MLE} = \frac{n_L}{m}$$

מא: MLE נא פא

$$y_k^{MLE} = \frac{1}{n_k} \sum_i \mathbb{1}_{y_i = k} x_i \quad \Sigma^{MLE} = \frac{1}{m} \sum_i (x_i - y_i^{MLE}) \cdot (x_i - y_i^{MLE})^T$$

ד. ש'ן לם ב' דימ'ת' סג' יס' י'ן בפנק' יו. א. ויפא'ר

לוחות, עשרה כרם. Lichelibooh. יג'ה בוקן!

$$\prod_{i=1}^n \mathcal{N}(x_i | \mu_{y_i}, \sigma_{y_i}^2) \cdot \mathcal{M}_{\text{ult}}(y_i, \pi)$$

log likelihood $\propto |S|$

$$= \sum_k \left[n_k \log(\pi_k) - \frac{1}{2} \sum_{i: y_i=k} (x_i - \mu_k)' (\sigma^2)^{-1} (x_i - \mu_k) \right] - \frac{m d}{2} \log(2\pi) - \frac{m}{2} \log |\sigma^2|$$

(Max likelihood)
(prior)
(likelihood)
(normal distribution)

$\mu_k^{MLE} = \frac{n_k}{m}$
 $\mu_{kj}^{MLE} = \frac{1}{n_k} \sum_{i: y_i=k} x_{ij}$
 $(\sigma^2)_{kj}^{MLE} = \frac{1}{n_k} \sum_{i: y_i=k} (x_{ij} - \mu_{kj}^{MLE})^2$

4. Likelihood, prior, posterior, evidence

$$\prod_{i=1}^m \text{Pois}(x_i | \mu_{y_i}, \lambda_{y_i}) \cdot \text{Mult}(y_i, \pi)$$

log-likelihood: $l(\theta | X, y)$

$$l(\theta | X, y) = \log \left(\prod_{i=1}^m \text{Pois}(x_i | \mu_{y_i}, \lambda_{y_i}) \cdot \text{Mult}(y_i, \pi) \right)$$

$$= \sum_{i=1}^m \log(\pi_{y_i}) - \log \left(\frac{\lambda_{y_i}^{x_i} e^{-\lambda_{y_i}}}{x_i!} \right)$$

$$= \sum_{i=1}^m \log(\pi_{y_i}) + x_i \log(\lambda_{y_i}) - \lambda_{y_i} - \log(x_i!)$$

$\frac{\partial l}{\partial \lambda_k} = \frac{1}{\lambda_k} \sum_{i: y_i=k} x_i - n_k = 0$

$$\lambda_k^{MLE} = \frac{1}{n_k} \sum_{i=1}^m \mathbb{1}_{y_i=k} x_i$$

(2.5) μ_k σ_k^2 n_k

$\hat{\mu}_k^{MLE} = \frac{n_k}{m}$

2.3. \log likelihood

$$\prod_{i=1}^d \prod_{j=1}^m \text{Pois}(X_i | \mu_{y_i, j_{y_i}}) \cdot \text{Mult}(y_i, \pi)$$

log-like / log-like - , \log \log \log \log

$$\sum_{i=1}^m \sum_{j \in T} \log(\pi_k) + x_{ij} \log(\pi_j) - \pi_j - \log(x_{ij}!)$$

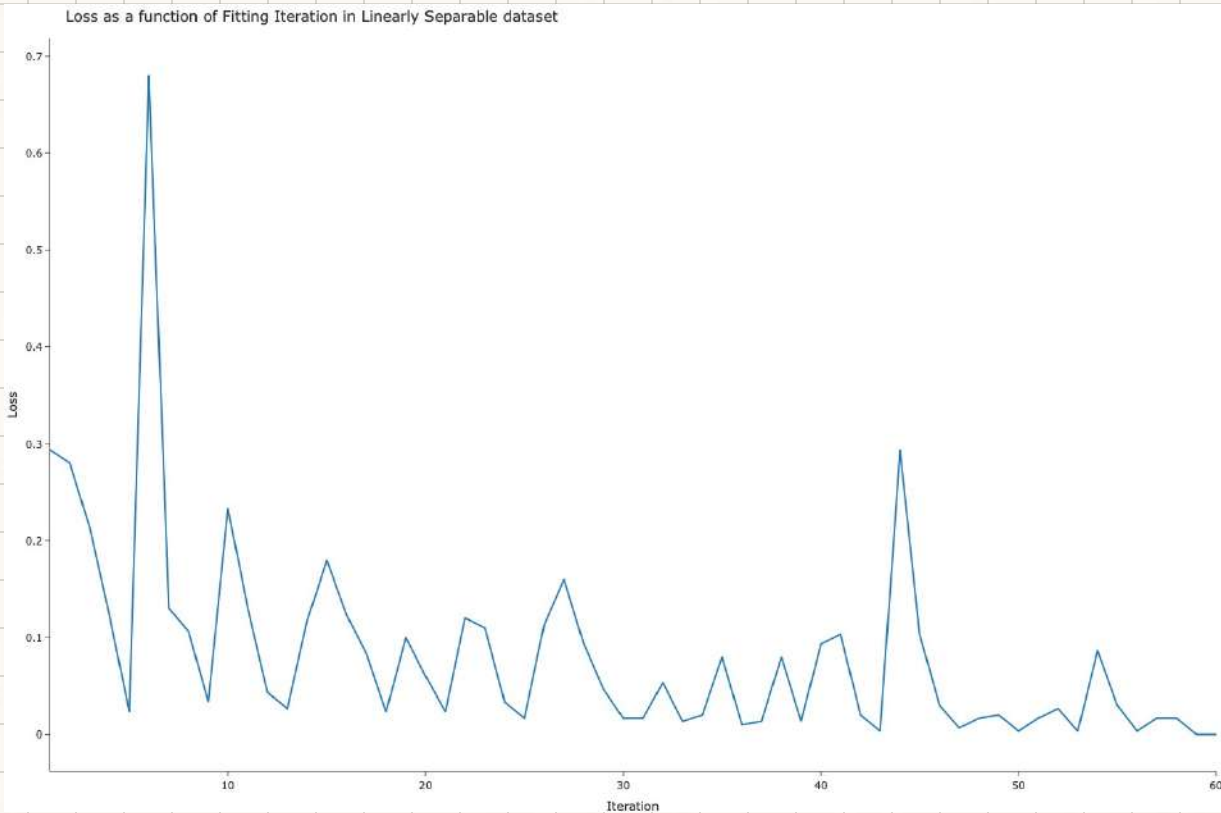
(הת'ול' י' ה' ו' ח' ט' י' י"א י"ב י"ג י"ד י"ה י"ו י"ז י"ח י"ט י"י)

1) תחסינון תתן פ רצו


$$\lambda_{ij}^{MLE} = \frac{1}{n_{i\cdot}} \sum_{j=1}^J 1_{y_i=j} x_{ij}$$

$$\text{NB} - g_L = \frac{h}{m}$$

המחלקה
10



(אין) חלק נגד זה שכל שנייה האלמנטים של Perceptron
 נמצא, ה MSE, ואז, כלים האלמנטים של רשת קונספיקציה
 טובה זה כך שזוהי אפס. ניתן להראות שהחלק האלמנטים
 ישנה "קונספיקציה" ה MSE, שכל הרגלים נובעים מהרשת
 גלגל נגד, האלמנטים ישו תזקוק אצד יש.



2.

בדף זה נראה כי הקוון ה- perceptron אינו מצליח להפחית

loss אפילו, ולא קשר במספר האיטרציות.

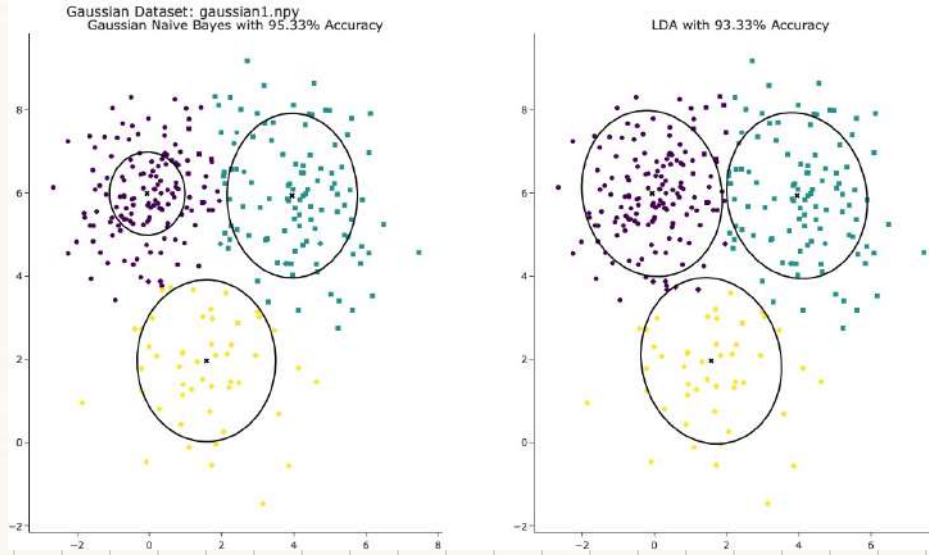
זה נובע מכך שאין בתוך האלמנטים עבור קוון שאין מופרזי

למארה, ואכן ולא קשר במספר האיטרציות, perceptron

לאחר מכן נראה כי יתקנה הנכונה, ואכן MSE נעלה


המספר המיוחס w, x, b, w - זה קוון (w, b) , כך ש

$$\forall: y_i < x_i, w \geq 0$$



3.

נתן נתונים מהזרמן הראשון כי ישנה השפעה של הדימור
 הדימור, ואם כן, אכן (הקטן) בין ה-LDA יי
 Gaussian Naive Bayes



4.

ההבדל בין 2 ו-1. הנתון הראשון שטן מקובל
 שונה השפעה שונה אפס ואכן ודימור של דימור
 היגאוסיאן עילית השפעה אפס ייחוד אנה נכונה
 אכן ה-LDA השפעה אפס אכן אכן